

Inteligência Artificial na Engenharia Aeroespacial

Minicurso panorâmico-aplicado — SEMUNI 2026

Prof. Dr. Victor Rafael Rezende Celestino

20 de setembro de 2026

Índice

Boas-vindas	4
Informações gerais	4
Síntese executiva	4
Público-alvo	5
Pré-requisitos desejáveis	5
Cronograma de 4 horas	5
Regra operacional do curso	5
Como navegar	6
1 Apresentação e filosofia do curso	7
1.1 Tese central	7
1.2 Diretriz pedagógica dos módulos	7
1.3 Escopo e limites	8
I Módulos do curso	9
2 Módulo 1 — Deep Learning, MLPs e PINNs	10
2.1 1. Objetivos de aprendizagem	10
2.2 2. Problema de engenharia	10
2.3 3. Classe de modelo de IA	10
2.4 4. Fundamentos conceituais	10
2.5 5. Formulação matemática mínima	10
2.6 6. Mapa de demonstração ao vivo	11
2.7 7. Links para abrir durante a aula	11
2.8 8. Notebook associado	11
2.9 9. Cuidados de engenharia	11
2.10 10. Questões de discussão	11
2.11 11. Possíveis projetos derivados	12
2.12 12. Leituras recomendadas	12
3 Módulo 2 — IA generativa, dados sintéticos e modelos substitutos	13
3.1 1. Objetivos de aprendizagem	13
3.2 2. Problema de engenharia	13
3.3 3. Classe de modelo de IA	13
3.4 4. Fundamentos conceituais	13
3.5 5. Formulação matemática mínima	13
3.6 6. Mapa de demonstração ao vivo	14
3.7 7. Links para abrir durante a aula	14
3.8 8. Notebook associado	14
3.9 9. Cuidados de engenharia	14
3.10 10. Questões de discussão	15
3.11 11. Possíveis projetos derivados	15

3.12	12. Leituras recomendadas	15
4	Módulo 3 — GNNs, otimização, MINLP e MPC	16
4.1	1. Objetivos de aprendizagem	16
4.2	2. Problema de engenharia	16
4.3	3. Classe de modelo de IA	16
4.4	4. Fundamentos conceituais	16
4.5	5. Formulação matemática mínima	16
4.6	6. Mapa de demonstração ao vivo	17
4.7	7. Links para abrir durante a aula	17
4.8	8. Notebook associado	17
4.9	9. Cuidados de engenharia	17
4.10	10. Questões de discussão	18
4.11	11. Possíveis projetos derivados	18
4.12	12. Leituras recomendadas	18
5	Módulo 4 — IA em MDO e projeto preliminar inspirado em AeroDesign	19
5.1	1. Objetivos de aprendizagem	19
5.2	2. Problema de engenharia	19
5.3	3. Classe de modelo de IA	19
5.4	4. Fundamentos conceituais	19
5.5	5. Formulação matemática mínima	19
5.6	6. Mapa de demonstração ao vivo	20
5.7	7. Links para abrir durante a aula	20
5.8	8. Notebook associado	20
5.9	9. Cuidados de engenharia	20
5.10	10. Questões de discussão	21
5.11	11. Possíveis projetos derivados	21
5.12	12. Leituras recomendadas	21
II	Recursos e fechamento	22
6	Recursos computacionais, datasets e repositórios	23
6.1	Bibliotecas e frameworks	23
6.2	Datasets e repositórios públicos	23
6.3	Política de dados	24
7	Referências	25

Boas-vindas

Este material organiza o minicurso **Inteligência Artificial na Engenharia Aeroespacial**, proposto para a **SEMUNI 2026 — FCTE/UnB**.

O minicurso tem caráter **panorâmico-aplicado**: em quatro horas, seu propósito não é formar especialistas em cada arquitetura, mas apresentar uma visão integrada de como inteligência artificial, simulação, modelos substitutos, grafos e otimização podem apoiar problemas de engenharia aeroespacial.

Informações gerais

Item	Descrição
Evento	SEMUNI 2026 — Semana Universitária da FCTE/UnB
Período previsto	20 a 25 de setembro de 2026
Título	Inteligência Artificial na Engenharia Aeroespacial
Carga horária	4 horas
Professor responsável	Prof. Dr. Victor Rafael Rezende Celestino
Formato	Exposição dialogada, roteiro navegável, demonstrações computacionais e discussão de aplicações
Natureza	Panorama aplicado sobre IA, simulação, otimização e projeto aeroespacial

Síntese executiva

A engenharia aeroespacial vem incorporando técnicas de aprendizado profundo, modelos generativos, redes neurais de grafo, simulação orientada por dados e otimização baseada em modelos. Essas técnicas ampliam a capacidade de modelar fenômenos, acelerar simulações, explorar alternativas de projeto e apoiar decisões em sistemas complexos, sem substituir os fundamentos físicos, matemáticos e experimentais da engenharia.

O minicurso articula quatro eixos:

1. **Deep Learning, MLPs e PINNs;**
2. **IA generativa, dados sintéticos e modelos substitutos;**
3. **GNNs, otimização combinatória, MINLP e MPC;**
4. **IA em otimização multidisciplinar e AeroDesign.**

Público-alvo

Estudantes de graduação e pós-graduação em Engenharia Aeroespacial, Engenharia Automotiva, Engenharia de Energia, Engenharia Eletrônica, Engenharia de Software, Computação, Ciência de Dados, Administração, Pesquisa Operacional e áreas afins; professores, pesquisadores e técnicos interessados na interseção entre inteligência artificial e aplicações aeroespaciais.

Pré-requisitos desejáveis

- Noções básicas de cálculo, álgebra linear e física;
- conhecimento introdutório de Python;
- fundamentos de engenharia;
- familiaridade inicial com aprendizado de máquina, embora não obrigatória.

Cronograma de 4 horas

Tempo	Bloco	Conteúdo principal
0:00–0:15	Abertura	Motivação, escopo panorâmico-aplicado e mapa do repositório
0:15–1:00	Módulo 1	MLPs, deep learning, PINNs e demonstração em PyTorch/DeepXDE
1:00–2:00	Módulo 2	IA generativa, dados sintéticos, geometrias e surrogate models
2:00–3:00	Módulo 3	GNNs, grafos bipartidos, MINLP, MPC e PyTorch Geometric/DGL
3:00–3:50	Módulo 4	IA, MDO, OpenMDAO, OpenVSP e estudo inspirado no AeroDesign
3:50–4:00	Fechamento	Síntese, bibliografia, repositório e oportunidades de projetos

Regra operacional do curso

Cada módulo terá **uma demonstração principal**. Conteúdos adicionais serão apresentados como leituras, desafios e extensões para estudo posterior.

Como navegar

Use o menu lateral para acessar os quatro módulos. Em cada módulo, procure as seções:

- problema de engenharia;
- classe de modelo de IA;
- fundamentos mínimos;
- roteiro de demonstração ao vivo;
- links para abrir durante a aula;
- notebook associado;
- cuidados de engenharia;
- projetos derivados.

1 Apresentação e filosofia do curso

1.1 Tese central

A inteligência artificial deve ser compreendida como **acelerador, aproximador e organizador de conhecimento** em engenharia aeroespacial, não como substituta dos princípios físicos, matemáticos e experimentais que sustentam a engenharia.

Em problemas aeroespaciais, modelos de IA podem:

- aproximar funções de alto custo computacional;
- apoiar a exploração de espaços de projeto;
- reduzir o tempo de simulações preliminares;
- extrair padrões de dados experimentais, numéricos ou operacionais;
- representar sistemas complexos por grafos;
- apoiar decisões em otimização e controle.

Contudo, esses modelos devem ser avaliados com rigor quanto a:

- domínio de validade;
- extrapolação;
- incerteza;
- consistência física;
- interpretabilidade;
- robustez computacional;
- rastreabilidade dos dados e hipóteses.

1.2 Diretriz pedagógica dos módulos

Cada módulo será guiado por três perguntas:

1. **Qual problema de engenharia está sendo tratado?**
2. **Qual classe de modelo de IA é adequada e por quê?**
3. **Quais cuidados de validação, extrapolação e consistência física devem ser observados?**

Essa estrutura busca conectar intuição física, formulação matemática e demonstração computacional.

1.3 Escopo e limites

Este minicurso é uma introdução aplicada. Em quatro horas, não é realista treinar profundamente os participantes em PyTorch, DeepXDE, PyTorch Geometric, DGL, OpenMDAO, OpenAeroStruct e OpenVSP. O objetivo é oferecer um mapa conceitual, um conjunto de exemplos e um repositório público para aprofundamento.

Parte I

Módulos do curso

2 Módulo 1 — Deep Learning, MLPs e PINNs

2.1 1. Objetivos de aprendizagem

Ao final deste módulo, espera-se que o participante seja capaz de:

- reconhecer o problema de engenharia associado ao módulo;
- compreender a intuição da classe de modelo de IA apresentada;
- identificar uma demonstração computacional mínima;
- avaliar riscos de extrapolação, validação e consistência física;
- localizar recursos públicos para aprofundamento.

2.2 2. Problema de engenharia

Predição e aproximação de respostas estruturais ou aerodinâmicas em problemas simplificados, especialmente quando há necessidade de combinar dados com restrições físicas.

2.3 3. Classe de modelo de IA

Perceptrons multicamadas, redes neurais profundas e redes neurais informadas pela física. O foco é compreender a progressão de MLPs para arquiteturas modernas e como PINNs incorporam resíduos de equações diferenciais na função de perda.

2.4 4. Fundamentos conceituais

MLP, função de ativação, treinamento por retropropagação, autograd, regularização, overfitting, modelos fundacionais e aprendizado físico-informado.

2.5 5. Formulação matemática mínima

Uma PINN pode ser vista como uma rede neural $(\hat{u}_\theta(x, t))$ treinada por uma função de perda composta:

$$\mathcal{L}(\theta) = \lambda_d \mathcal{L}_{dados} + \lambda_f \mathcal{L}_{física} + \lambda_b \mathcal{L}_{contorno} + \lambda_i \mathcal{L}_{inicial}.$$

A contribuição física geralmente envolve o resíduo de uma equação diferencial:

$$r_\theta(x, t) = \mathcal{N}[\hat{u}_\theta](x, t),$$

onde $(\mathcal{N})$ representa o operador diferencial do problema.

2.6 6. Mapa de demonstração ao vivo

	Passo	Ação em sala	Mensagem didática
	1	Abrir a página do módulo no GitHub Pages	Apresentar o problema de engenharia
	2	Abrir o notebook associado	Mostrar o fluxo computacional mínimo
	3	Executar ou comentar as células principais	Relacionar código, modelo e hipótese física
	4	Alterar um parâmetro simples	Evidenciar sensibilidade e limites do modelo
	5	Discutir validação	Evitar uso acrítico da IA em engenharia

2.7 7. Links para abrir durante a aula

- PyTorch Documentation;
- DeepXDE Documentation;
- NASA Airfoil Self-Noise Dataset;
- repositórios introdutórios de PINNs em PyTorch.

2.8 8. Notebook associado

Notebook principal: `notebooks/01_mlp_pinn_pytorch.ipynb`

Quando o repositório estiver publicado no GitHub, este espaço receberá o botão direto para abertura no Google Colab.

2.9 9. Cuidados de engenharia

- Não interpretar baixa perda de treinamento como validade física geral;
- verificar condições de contorno;
- analisar extrapolação fora do domínio treinado;
- comparar com solução analítica, numérica ou experimental quando disponível.

2.10 10. Questões de discussão

- Quando uma PINN é preferível a uma rede puramente orientada por dados?
- Que riscos surgem quando a física é mal especificada?
- Como escolher pesos entre dados, resíduo físico e condições de contorno?

2.11 11. Possíveis projetos derivados

- PINN para viga Euler-Bernoulli simplificada;
- MLP para aproximação de coeficientes aerodinâmicos;
- comparação entre regressão clássica, MLP e PINN.

2.12 12. Leituras recomendadas

- Goodfellow et al. (2016)
- LeCun et al. (2015)
- Raissi et al. (2019)
- Karniadakis et al. (2021)
- Brunton e Kutz (2022)

3 Módulo 2 — IA generativa, dados sintéticos e modelos substitutos

3.1 1. Objetivos de aprendizagem

Ao final deste módulo, espera-se que o participante seja capaz de:

- reconhecer o problema de engenharia associado ao módulo;
- compreender a intuição da classe de modelo de IA apresentada;
- identificar uma demonstração computacional mínima;
- avaliar riscos de extrapolação, validação e consistência física;
- localizar recursos públicos para aprofundamento.

3.2 2. Problema de engenharia

Geração de dados sintéticos, exploração de geometrias e construção de modelos substitutos para reduzir custo computacional em simulações aeroespaciais.

3.3 3. Classe de modelo de IA

Modelos generativos, incluindo VAEs, GANs, modelos de difusão, modelos autorregressivos e mecanismos de atenção. O módulo enfatiza também surrogate models como aproximadores de simulações caras.

3.4 4. Fundamentos conceituais

Distribuição de dados, espaço latente, codificador, decodificador, discriminador, difusão, atenção, plausibilidade física, aumento de dados e aprendizado ativo.

3.5 5. Formulação matemática mínima

Um modelo substituto busca aproximar uma função de alto custo:

$$y = f(x) \quad \Rightarrow \quad \hat{y} = \hat{f}_\theta(x),$$

em que (f) pode representar uma simulação CFD, análise estrutural ou cálculo de desempenho.

Em um VAE, o treinamento combina reconstrução e regularização probabilística:

$$\mathcal{L} = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] - D_{KL}(q_\phi(z|x) \| p(z)).$$

3.6 6. Mapa de demonstração ao vivo

Passo	Ação em sala	Mensagem didática
1	Abrir a página do módulo no GitHub Pages	Apresentar o problema de engenharia
2	Abrir o notebook associado	Mostrar o fluxo computacional mínimo
3	Executar ou comentar as células principais	Relacionar código, modelo e hipótese física
4	Alterar um parâmetro simples	Evidenciar sensibilidade e limites do modelo
5	Discutir validação	Evitar uso acrítico da IA em engenharia

3.7 7. Links para abrir durante a aula

- NASA Airfoil Self-Noise Dataset;
- UIUC Airfoil Data Site;
- ShapeNet / ShapeNet Part;
- PyTorch Documentation;
- exemplos de surrogate modeling em Scikit-learn e PyTorch.

3.8 8. Notebook associado

Notebook principal: `notebooks/02_surrogate_dados_sinteticos.ipynb`

Quando o repositório estiver publicado no GitHub, este espaço receberá o botão direto para abertura no Google Colab.

3.9 9. Cuidados de engenharia

- Dados sintéticos não substituem validação experimental;
- geometrias geradas precisam respeitar restrições físicas e operacionais;
- surrogate models podem falhar severamente fora do domínio de treinamento;
- métricas estatísticas devem ser combinadas com julgamento de engenharia.

3.10 10. Questões de discussão

- Como validar dados sintéticos em engenharia?
- Quando um surrogate model é suficiente para decisão preliminar?
- Que tipo de erro é aceitável em projeto conceitual?

3.11 11. Possíveis projetos derivados

- modelo substituto para ruído de aerofólio;
- geração de amostras sintéticas de configurações de asa;
- comparação entre Gaussian Process, Random Forest e MLP para regressão aerodinâmica.

3.12 12. Leituras recomendadas

- Goodfellow et al. (2014)
- Kingma e Welling (2013)
- Ho et al. (2020)
- Rombach et al. (2022)
- Forrester et al. (2008)

4 Módulo 3 — GNNs, otimização, MINLP e MPC

4.1 1. Objetivos de aprendizagem

Ao final deste módulo, espera-se que o participante seja capaz de:

- reconhecer o problema de engenharia associado ao módulo;
- compreender a intuição da classe de modelo de IA apresentada;
- identificar uma demonstração computacional mínima;
- avaliar riscos de extrapolação, validação e consistência física;
- localizar recursos públicos para aprofundamento.

4.2 2. Problema de engenharia

Representação de sistemas complexos, malhas, componentes, restrições e problemas de otimização por meio de grafos, com aplicações em otimização combinatória, MINLP e controle preditivo.

4.3 3. Classe de modelo de IA

Redes neurais de grafo, grafos bipartidos, embeddings e message passing. O módulo apresenta como problemas de otimização podem ser representados por variáveis, restrições e relações estruturais.

4.4 4. Fundamentos conceituais

Nós, arestas, atributos, grafos bipartidos, embeddings, agregação de vizinhança, message passing, warm start, predição de variáveis ativas e suporte a decisões em horizonte móvel.

4.5 5. Formulação matemática mínima

Em uma GNN, uma etapa genérica de message passing pode ser escrita como:

$$m_i^{(k)} = \sum_{j \in \mathcal{N}(i)} \phi^{(k)}(h_i^{(k)}, h_j^{(k)}, e_{ij}),$$

$$h_i^{(k+1)} = \psi^{(k)}(h_i^{(k)}, m_i^{(k)}),$$

onde (h_i) é a representação do nó, (e_{ij}) representa atributos da aresta e $(\mathcal{N}(i))$ é a vizinhança de (i) .

4.6 6. Mapa de demonstração ao vivo

	Passo	Ação em sala	Mensagem didática
	1	Abrir a página do módulo no GitHub Pages	Apresentar o problema de engenharia
	2	Abrir o notebook associado	Mostrar o fluxo computacional mínimo
	3	Executar ou comentar as células principais	Relacionar código, modelo e hipótese física
	4	Alterar um parâmetro simples	Evidenciar sensibilidade e limites do modelo
	5	Discutir validação	Evitar uso acrítico da IA em engenharia

4.7 7. Links para abrir durante a aula

- PyTorch Geometric Documentation;
- DGL Documentation;
- MIPLIB;
- MILPBench;
- benchmarks de facility location;
- materiais introdutórios sobre aprendizado para otimização.

4.8 8. Notebook associado

Notebook principal: `notebooks/03_gnn_bipartite_minlp.ipynb`

Quando o repositório estiver publicado no GitHub, este espaço receberá o botão direto para abertura no Google Colab.

4.9 9. Cuidados de engenharia

- GNNs podem capturar padrões estruturais, mas não garantem otimalidade;
- decisões geradas por IA devem ser verificadas por solucionadores ou regras de viabilidade;
- benchmarks de otimização nem sempre representam sistemas aeroespaciais reais;
- MPC exige tratamento rigoroso de estabilidade, restrições e robustez.

4.10 10. Questões de discussão

- Como representar um problema de otimização como grafo bipartido?
- GNN deve substituir ou auxiliar o solver?
- Como validar uma política aproximada em MPC?

4.11 11. Possíveis projetos derivados

- grafo bipartido para pequeno problema MILP;
- classificação de variáveis candidatas a zero/um;
- warm start orientado por aprendizado;
- GNN para rede simplificada de componentes aeroespaciais.

4.12 12. Leituras recomendadas

- Kipf e Welling (2017)
- Gilmer et al. (2017)
- Battaglia et al. (2018)
- Fey e Lenssen (2019)
- Zhou et al. (2020)
- Rawlings et al. (2017)

5 Módulo 4 — IA em MDO e projeto preliminar inspirado em AeroDesign

5.1 1. Objetivos de aprendizagem

Ao final deste módulo, espera-se que o participante seja capaz de:

- reconhecer o problema de engenharia associado ao módulo;
- compreender a intuição da classe de modelo de IA apresentada;
- identificar uma demonstração computacional mínima;
- avaliar riscos de extrapolação, validação e consistência física;
- localizar recursos públicos para aprofundamento.

5.2 2. Problema de engenharia

Projeto preliminar de aeronaves de pequeno porte com disciplinas acopladas: aerodinâmica, estruturas, massa, propulsão, desempenho, estabilidade e restrições operacionais.

5.3 3. Classe de modelo de IA

Modelos substitutos, otimização bayesiana, aprendizado ativo e integração com frameworks de otimização multidisciplinar, especialmente OpenMDAO e ferramentas de geometria conceitual.

5.4 4. Fundamentos conceituais

Variáveis de projeto, funções objetivo, restrições, disciplinas acopladas, análise de sensibilidade, metamodelos, trade-offs e busca em espaços de configuração.

5.5 5. Formulação matemática mínima

Um problema MDO simplificado pode ser escrito como:

$$\min_x F(x)$$

sujeito a:

$$g_i(x) \leq 0, \quad i = 1, \dots, m,$$

$$h_j(x) = 0, \quad j = 1, \dots, p,$$

em que (x) representa variáveis de projeto, $(F(x))$ é a função objetivo e (g_i, h_j) representam restrições de engenharia.

5.6 6. Mapa de demonstração ao vivo

Passo	Ação em sala	Mensagem didática
1	Abrir a página do módulo no GitHub Pages	Apresentar o problema de engenharia
2	Abrir o notebook associado	Mostrar o fluxo computacional mínimo
3	Executar ou comentar as células principais	Relacionar código, modelo e hipótese física
4	Alterar um parâmetro simples	Evidenciar sensibilidade e limites do modelo
5	Discutir validação	Evitar uso acrítico da IA em engenharia

5.7 7. Links para abrir durante a aula

- OpenMDAO Documentation;
- OpenAeroStruct Documentation;
- OpenVSP Documentation;
- UIUC Airfoil Data Site;
- materiais públicos de AeroDesign e projeto conceitual de aeronaves.

5.8 8. Notebook associado

Notebook principal: `notebooks/04_mdo_aerodesign_openmdao.ipynb`

Quando o repositório estiver publicado no GitHub, este espaço receberá o botão direto para abertura no Google Colab.

5.9 9. Cuidados de engenharia

- Modelos preliminares devem ser tratados como apoio à decisão, não como certificação;
- acoplamentos entre disciplinas podem gerar efeitos não intuitivos;
- restrições estruturais, operacionais e de segurança devem prevalecer sobre ganho de função objetivo;
- otimização sem validação pode produzir soluções inviáveis.

5.10 10. Questões de discussão

- Como definir variáveis de projeto relevantes para uma aeronave de pequeno porte?
- Qual é o papel de um surrogate model em MDO?
- Como lidar com trade-offs entre carga paga, decolagem, massa e desempenho aerodinâmico?

5.11 11. Possíveis projetos derivados

- MDO simplificado de asa para AeroDesign;
- surrogate model para estimar carga paga;
- estudo de sensibilidade de alongamento e área de asa;
- integração OpenVSP–OpenMDAO em projeto conceitual.

5.12 12. Leituras recomendadas

- Martins e Ning (2021)
- Gray et al. (2019)
- Jasa et al. (2018)
- Forrester et al. (2008)
- Brunton e Kutz (2022)

Parte II

Recursos e fechamento

6 Recursos computacionais, datasets e repositórios

6.1 Bibliotecas e frameworks

Recurso	Uso no minicurso
Python, NumPy, SciPy, Pandas, Matplotlib, Scikit-learn	Manipulação de dados, modelagem, regressão e visualização
PyTorch	Construção de MLPs, redes profundas e protótipos de PINNs
DeepXDE	Alternativa especializada para redes neurais informadas pela física
PyTorch Geometric	Construção e treinamento de GNNs
DGL	Alternativa para modelagem e treinamento de GNNs
OpenMDAO	Análise e otimização multidisciplinar
OpenAeroStruct	Otimização aeroestrutural acoplada
OpenVSP	Modelagem paramétrica e análise conceitual de aeronaves
Pyomo e SciPy Optimize	Modelagem e solução de problemas de otimização

6.2 Datasets e repositórios públicos

Recurso	Uso didático
NASA Airfoil Self-Noise	Regressão aplicada à aerodinâmica/acústica de aerofólios
UIUC Airfoil Data Site	Coordenadas de aerofólios para estudos preliminares de geometria
NPARC Alliance / NASA CFD resources	Discussão de validação computacional e fluidodinâmica
ShapeNet / ShapeNet Part	Representação geométrica, nuvens de pontos e IA generativa
MIPLIB	Benchmarks de programação inteira mista
MILPBench e facility location benchmarks	Aprendizado para otimização e geração de warm starts
Repositórios de PINNs em PyTorch e DeepXDE	Exemplos de EDOs, EDPs e sistemas físicos

Recurso	Uso didático
Repositórios OpenMDAO e OpenAeroStruct	Exemplos de MDO, análise aeroestrutural e otimização

6.3 Política de dados

Este repositório não redistribui datasets de terceiros por padrão. Sempre que possível, serão fornecidos links, instruções de acesso e scripts de download, respeitando as licenças originais.

7 Referências

- Battaglia, Peter W., Jessica B. Hamrick, Victor Bapst, et al. 2018. *Relational inductive biases, deep learning, and graph networks*. <https://arxiv.org/abs/1806.01261>.
- Brunton, Steven L., e J. Nathan Kutz. 2022. *Data-Driven Science and Engineering: Machine Learning, Dynamical Systems, and Control*. 2^o ed. Cambridge University Press.
- Fey, Matthias, e Jan Eric Lenssen. 2019. “Fast Graph Representation Learning with PyTorch Geometric”. *ICLR Workshop on Representation Learning on Graphs and Manifolds*.
- Forrester, Alexander, Andras Sobester, e Andy Keane. 2008. *Engineering Design via Surrogate Modelling: A Practical Guide*. Wiley.
- Gilmer, Justin, Samuel S. Schoenholz, Patrick F. Riley, Oriol Vinyals, e George E. Dahl. 2017. “Neural Message Passing for Quantum Chemistry”. *International Conference on Machine Learning*, 1263–72.
- Goodfellow, Ian, Yoshua Bengio, e Aaron Courville. 2016. *Deep Learning*. MIT Press.
- Goodfellow, Ian, Jean Pouget-Abadie, Mehdi Mirza, et al. 2014. “Generative Adversarial Nets”. *Advances in Neural Information Processing Systems*.
- Gray, Justin S., John T. Hwang, Joaquim R. R. A. Martins, Kenneth T. Moore, e Bret A. Naylor. 2019. “OpenMDAO: An open-source framework for multidisciplinary design, analysis, and optimization”. *Structural and Multidisciplinary Optimization* 59: 1075–104.
- Ho, Jonathan, Ajay Jain, e Pieter Abbeel. 2020. “Denoising Diffusion Probabilistic Models”. *Advances in Neural Information Processing Systems*.
- Jasa, John P., John T. Hwang, e Joaquim R. R. A. Martins. 2018. “Open-source coupled aerostructural optimization using Python”. *Structural and Multidisciplinary Optimization* 57: 1815–27.
- Karniadakis, George Em, Ioannis G. Kevrekidis, Lu Lu, Paris Perdikaris, Sifan Wang, e Liu Yang. 2021. “Physics-informed machine learning”. *Nature Reviews Physics* 3: 422–40.
- Kingma, Diederik P., e Max Welling. 2013. *Auto-Encoding Variational Bayes*. <https://arxiv.org/abs/1312.6114>.
- Kipf, Thomas N., e Max Welling. 2017. “Semi-Supervised Classification with Graph Convolutional Networks”. *International Conference on Learning Representations*.
- LeCun, Yann, Yoshua Bengio, e Geoffrey Hinton. 2015. “Deep learning”. *Nature* 521: 436–44.

- Martins, Joaquim R. R. A., e Andrew Ning. 2021. *Engineering Design Optimization*. Cambridge University Press.
- Raissi, Maziar, Paris Perdikaris, e George E. Karniadakis. 2019. “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations”. *Journal of Computational Physics* 378: 686–707.
- Rawlings, James B., David Q. Mayne, e Moritz Diehl. 2017. *Model Predictive Control: Theory, Computation, and Design*. Nob Hill Publishing.
- Rombach, Robin, Andreas Blattmann, Dominik Lorenz, Patrick Esser, e Bjorn Ommer. 2022. “High-Resolution Image Synthesis with Latent Diffusion Models”. *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 10684–95.
- Zhou, Jie, Ganqu Cui, Shengding Hu, et al. 2020. “Graph neural networks: A review of methods and applications”. *AI Open* 1: 57–81.